

**UAX**

**TRABAJO FIN DE MÁSTER**

**MUIA  
24-25**

**UNIVERSIDAD ALFONSO X EL SABIO**

**Business Tech**

**Máster Universitario en Inteligencia Artificial**



## **TRABAJO DE FIN DE MÁSTER**

**Modelos de predicción de actividad solar extrema  
a partir de observaciones satelitales y aprendizaje  
profundo**

**Luka Giannotti San Juan  
Juan Agustín Fraile Nieto**

**10/2025**

## RESUMEN

Se aborda la predicción de actividad solar extrema mediante el uso combinado de observaciones satelitales y técnicas de aprendizaje profundo. El estudio se centra en dos fenómenos provenientes del sol: las fulguraciones solares y las eyecciones de masa coronal (CMEs).

Para ello se han recopilado y procesado datos de los satélites GOES-18, SDO y SOHO asegurando su alineación temporal y calidad. El flujo de rayos X de GOES se ha empleado para estudiar las fulguraciones mientras que los parámetros magnéticos de SHARP (SDO) se han utilizado para predecir las CMEs. Tras un preprocesamiento, que incluye normalizar, etiquetar y aplicar umbrales, se han desarrollado dos modelos de redes neuronales: Una CNN unidimensional y una LSTM para ambos fenómenos. En el caso de las fulguraciones, ambas arquitecturas han mostrado un alto rendimiento (CNN: recall=0.88 y precisión=0.55; LSTM: recall=0.86 y precisión=0.55) demostrando un patrón radiativo claro antes de cada evento. En las CMEs, el rendimiento fue muy limitado (AUC = 0.55 y precisión 0.2) en ambos modelos, reflejando la dificultad de predecir este tipo de eventos.

Los resultados indican que la inteligencia artificial constituye una herramienta eficaz para la predicción de fulguraciones, mientras que para la predicción de CMEs hace falta mayor contexto y la integración de datos coronales y no fotosféricas. El proyecto sienta las bases para futuros sistemas de detección temprana solar con una propuesta metodológica adaptable y reproducible.

## Palabras clave

Aprendizaje profundo, Convolutional Neural Network (CNN), Long Short-Term memory network (LSTM), fulguraciones solares, eyecciones de masa coronal (CMEs).

## ABSTRACT

This work addresses the prediction of extreme solar activity through the combined use of satellite observations and deep learning techniques. The study focuses on two phenomena: solar flares and coronal mass ejections (CMEs).

Data from the GOES-18, SDO, and SOHO satellites were collected and processed, ensuring temporal alignment and quality control. The X-ray flux from GOES was used to study flares, while the magnetic parameters from SHARP (SDO) were employed to predict CMEs. After preprocessing — including normalization, labeling, and thresholding— two neural network models were developed: a one-dimensional CNN and an LSTM, applied to both phenomena. For flares, both architectures showed high performance (CNN: recall = 0.88, precision = 0.55; LSTM: recall = 0.86, precision = 0.55), revealing a clear radiative pattern before each event. For CMEs, however, performance was very limited (AUC = 0.54; precision = 0.2) in both models, reflecting the intrinsic difficulty of predicting these large-scale coronal events.

The results demonstrate that artificial intelligence is an effective tool for solar flare forecasting, while CME prediction still requires greater physical context and the integration of coronal rather than photospheric data. This project lays the groundwork for future early solar warning systems through a methodological framework that is both adaptable and reproducible.

## Keywords

Deep learning, Convolutional Neural Network (CNN), Long Short-Term memory network (LSTM), solar flares, coronal mass ejections (CMEs).

# ÍNDICE

|                                                                                          |           |
|------------------------------------------------------------------------------------------|-----------|
| <b>Capítulo 1: Introducción al Trabajo Fin de Máster .....</b>                           | <b>6</b>  |
| 1. Justificación del proyecto realizado.....                                             | 7         |
| 1.1. Motivación personal .....                                                           | 7         |
| 1.2. Relevancia científica.....                                                          | 7         |
| 1.3. Relevancia tecnológica y social.....                                                | 9         |
| 1.4. Relevancia educativa.....                                                           | 10        |
| 2. Presentación del proyecto y sus contenidos.....                                       | 11        |
| <b>Capítulo 2: Objetivos del TFM.....</b>                                                | <b>12</b> |
| 1. Objetivo general .....                                                                | 13        |
| 2. Objetivos específicos.....                                                            | 13        |
| <b>Capítulo 3: Marco Teórico.....</b>                                                    | <b>15</b> |
| 3.1 Actividad solar y estructura del Sol.....                                            | 16        |
| 3.1.1 Estructura general del Sol.....                                                    | 17        |
| 3.1.2 Campo magnético solar y ciclo de actividad .....                                   | 18        |
| 3.2 Fenómenos asociados a la actividad solar .....                                       | 20        |
| 3.2.1 Fulguraciones solares .....                                                        | 20        |
| 3.2.2 Eyecciones de masa coronal (CMEs).....                                             | 22        |
| 3.2.3 Consecuencias en la Tierra y el entorno espacial .....                             | 24        |
| 3.3 Predicción de la actividad solar: del modelo físico a la inteligencia artificial ... | 25        |
| 3.3.1 Modelos tradicionales .....                                                        | 25        |
| 3.3.2 Inteligencia artificial aplicada a la predicción solar.....                        | 26        |
| 3.3.3 Estado del arte .....                                                              | 27        |
| <b>Capítulo 4: Marco Metodológico.....</b>                                               | <b>29</b> |
| 4.1 Población y muestra .....                                                            | 32        |
| 4.2 Variables intervinientes e instrumentos de evaluación.....                           | 33        |
| 4.3 Diseño experimental .....                                                            | 35        |
| 4.4 Modelo de análisis de datos .....                                                    | 37        |
| 4.4.1 Métricas de rendimiento.....                                                       | 38        |
| 4.4.2 Criterios de interpretación y validez .....                                        | 39        |

|                                                                           |           |
|---------------------------------------------------------------------------|-----------|
| <b>Capítulo 5: Presentación de análisis, resultados y discusión .....</b> | <b>40</b> |
| 5.1 Análisis descriptivo de la muestra .....                              | 41        |
| 5.2 Resultados obtenidos.....                                             | 44        |
| 5.3 Discusión y análisis de los resultados .....                          | 49        |
| <b>Capítulo 6: Conclusiones .....</b>                                     | <b>51</b> |
| 6.1 Limitaciones.....                                                     | 54        |
| 6.2 Prospectiva.....                                                      | 55        |
| 6.3 Consideraciones finales.....                                          | 56        |
| <b>Bibliografía.....</b>                                                  | <b>59</b> |

## Capítulo 1: Introducción al Trabajo Fin de Máster

El presente Trabajo Fin de Máster aborda la predicción de la actividad solar extrema mediante observaciones satelitales y modelos de aprendizaje profundo. Se consideran eventos de interés principalmente las fulguraciones, liberaciones repentinas de energía en forma de radiación electromagnética, y las eyecciones de masa coronal (CMEs), enormes nubes de plasma magnetizado expulsadas desde la corona solar. En el caso de las CMEs, cuando estas partículas interactúan con la magnetosfera terrestre, pueden producir tormentas geomagnéticas. Estas tormentas se clasifican en la escala G de NOAA, donde un evento, por ejemplo, G5, representa el nivel más extremo con impacto en satélites, comunicaciones, navegación y/o redes eléctricas. (Shibata & Magara, 2011) (Chen, 2011)

Durante el ciclo solar actual (Ciclo 25, iniciado en 2019), la actividad ha sido más intensa y temprana de lo que se había previsto, con episodios de tormenta G5 en mayo de 2024, la primera de este nivel en más de dos décadas, además de numerosos periodos de fuerte actividad, lo que produjo auroras a latitudes inusuales y obligó a emitir avisos operativos. Esto indica la relevancia de predecir estos fenómenos de manera temprana.

En este capítulo se justifica el proyecto desde una perspectiva científica, tecnológica y social, y se presenta la estructura con la que se trabaja. De la misma manera, se indican fuentes de datos abiertas y figuras para contextualizar cualitativamente el problema.

## 1. Justificación del proyecto realizado

### 1.1. Motivación personal

Este proyecto nace de la intersección de dos de mis áreas de estudio: la física y la inteligencia artificial. Durante mi formación en Física he trabajado con modelos que describen fenómenos no lineales, desde la mecánica cuántica hasta la dinámica de fluidos, y es común en todos estos campos la dificultad de predecir el comportamiento de sistemas muy sensibles a ciertas condiciones. La actividad solar extrema, con sus ciclos, fulguraciones y CMEs es un buen ejemplo de este tipo de sistemas.

De la misma manera, la otra área de conocimiento en el que me estoy adentrando es la inteligencia artificial, la cual me puede proporcionar herramientas que permiten estudiar este tipo de sistemas desde otro ángulo completamente diferente, con ayuda de grandes volúmenes de datos y la extracción de patrones mediante modelos estadísticos de aprendizaje profundo.

Estas perspectivas combinadas es la motivación para mi estudio, emprender un proyecto que combine el rigor físico y la metodología computacional, con la convicción de que la formación que he realizado me capacita para integrarlas coherentemente.

### 1.2. Relevancia científica

Comenzamos con las fulguraciones. Estas son liberaciones súbitas de energía electromagnética que se producen en la atmósfera solar y están asociadas a procesos de reconexión magnética en la corona (Shibata & Magara, 2011). Estas fulguraciones calientan el plasma a decenas millones de grados y aceleran partículas a altísimas velocidades. Su energía puede alcanzar los  $10^{32} \text{ erg}$  en cuestión de minutos, lo que equivale a liberar, aproximadamente, la energía de millones de bombas de hidrógeno de manera casi simultánea, o

a unas decenas de miles de veces el consumo energético anual actual de toda la humanidad. Para clasificar la intensidad de estas liberaciones de energía, los satélites GOES utilizan el flujo de rayos X en el rango de  $0.1 - 0.8nm$ , que se organizan en cinco clases: A, B, C, M y X. Cada una de estas clases representa un aumento de orden de magnitud del flujo, las fulguraciones de clase A son las más débiles ( $\geq 10^{-8}W/m^2$ ), las de clase B dos órdenes de magnitud más intensas ( $\geq 10^{-7}W/m^2$ ), las de clase C moderadas ( $\geq 10^{-6}W/m^2$ ), las de clase M fuertes ( $\geq 10^{-5}W/m^2$ ) y las de clase X extremas ( $\geq 10^{-4}W/m^2$  o superiores).

*Figura 1: Fulguración solar, 16 abril 2012. (NASA/SDO/AIA)*




Estas fulguraciones son el origen de las eyecciones de masa coronal (CMEs), que corresponden a la expulsión de grandes cantidades de plasma magnético hacia el espacio interplanetario, con masas del orden de  $10^{15} - 10^{16}g$  y velocidades que pueden superar los  $2000km/s$ .

Los ciclos solares son los que regulan la frecuencia de estos fenómenos. En los puntos mínimos de actividad de estos se observa una CME por semana aproximadamente, mientras que en los puntos de actividad máximos se pueden observar 2-3 por día. Esta variabilidad es la que dificulta la predicción, aunque ofrece una base estadística para entrenar modelos basados en series temporales y aprendizaje automático.



Hoy en día existen modelos magnetohidrodinámicos (MHD) que permiten explicar como el plasma y los campos magnéticos generan fulguraciones y CMEs, pero son muy complejos y costosos de calcular, por lo que aquí es donde la inteligencia artificial podría suponer un gran avance: en lugar de resolver ecuaciones físicas, se entrenan algoritmos para detectar patrones y anticiparse a eventos reales. Ya se han utilizado clasificadores de fulguraciones o redes neuronales profundas para combinar imágenes y magnetogramas para mejorar estas predicciones.

*Figura 2: Actividad solar: diferencia entre fulguraciones (Flare) y CMEs.*



### 1.3. Relevancia tecnológica y social

El impacto de la actividad extrema solar en la sociedad de hoy en día es significativo. Cuando las partículas y campos expulsados por una CME alcanzan la Tierra, estas pueden generar lo que se llaman tormentas geomagnéticas, que vienen a ser perturbaciones en el campo magnético terrestre. La intensidad de estas tormentas se clasifica según la escala G de NOAA (Administración Nacional Oceánica y Atmosférica), de G1 (menor) a G5 (extrema). Cuanto mayor G, mayor es la perturbación en el campo magnético. Para ponerlo en contexto, un evento G5 puede producir fallos

generalizados en redes eléctricas, transformadores y sistemas GPS, además de auroras visibles en latitudes medianas y bajas.

Ya ha habido episodios en la historia como el evento de Carrington de 1859 que provocó auroras visibles hasta en zonas ecuatoriales, o mas recientemente la tormenta de marzo de 1989 que ocasionó un apagón de nueve horas en Quebec afectando a millones de personas (Boteler, D.H., 2019). En mayo de 2024 la primera tormenta G5 en más de veinte años puso a prueba la resistencia de los sistemas modernos, confirmando que sigue habiendo riesgos con estas actividades extremas solares.

Si a eso le añadimos cada vez la dependencia tecnológica de la sociedad de hoy en día, tanto de las redes eléctricas de alta tensión, la navegación GPS o las comunicaciones satelitales, este estudio no solo tendría interés académico sino también podría tener una necesidad estratégica.

#### 1.4. Relevancia educativa

Desde el punto de vista formativo, se propone este proyecto como oportunidad para aplicar los conocimientos adquiridos en el Máster de Inteligencia Artificial a un problema real del área de la Física. Este estudio obliga la combinación de procesos Físicos que dan lugar a la actividad solar, con la capacidad de entrenar y evaluar modelos de IA. Esta fusión fortalece competencias como el análisis crítico de datos, el uso de herramientas computacionales avanzadas y la interpretación científica de los resultados.

Finalmente, se espera que el trabajo de carácter interdisciplinar que se propone sienta una base firme para afrontar futuros retos de predicción dentro de diferentes ámbitos como puede ser el ámbito climático, energético o el de la salud.

## 2. Presentación del proyecto y sus contenidos

La base de este estudio es la dificultad de predecir la ocurrencia y la intensidad de los fenómenos solares extremos definidos anteriormente, dada su naturaleza caótica. Los modelos físicos son fundamentales para entender los procesos de estos fenómenos, pero no son suficientes para ofrecer predicciones acertadas y rápidas. Este trabajo pretende aportar una aproximación que complemente el estudio a través de la física mediante la aplicación de modelos de aprendizaje profundo a datos satelitales abiertos (GOES, SDO, SOHO), con el objetivo de observar, estudiar y comparar su rendimiento frente a métodos estadísticos más tradicionales.

La organización del documento será la siguiente:

- El Capítulo 1 introduce el trabajo justificando su elección explicando la importancia de las predicciones de fenómenos solares extremos tanto en el ámbito científico, tecnológico y social. Finalmente presenta la estructura general del proyecto. Este capítulo sirve como carta de presentación del estudio y guía sobre lo que se va a encontrar durante la lectura.
- El Capítulo 2 define los objetivos específicos y el objetivo general del proyecto. En este apartado se detallan las metas que guiarán la investigación, diferenciando los objetivos concretos de cada paso y el objetivo global del trabajo.
- El Capítulo 3 trata de constituir una base conceptual teórica sobre la que se apoya el trabajo. Primero se presentan los fundamentos de la actividad solar, explicando en detalle qué son las fulguraciones y las eyecciones de masa coronal (CMEs) y cómo se relacionan con el ciclo solar. A continuación, se introducen las escalas empleadas por la

NOAA para clasificar las fulguraciones y las tormentas geomagnéticas que éstas pueden generar. Finalmente, también se realizará una revisión del estado del arte en predicción de eventos solares, desde métodos más tradicionales hasta enfocados en IA y Deep learning.

- El Capítulo 4 describe y detalla la procedencia de los datos empleados para el estudio, los satélites o bases de datos que se han utilizado y con qué criterio se han seleccionado las variables relevantes. Se explica desde el proceso de preprocesamiento, que incluye la limpieza y normalización de las series temporales. Se presentan también los modelos que se evaluarán, describiendo sus características principales. Finalmente, se expondrán también métricas para valorar el rendimiento del modelo.
- El Capítulo 5 presenta los resultados experimentales obtenidos a partir de los distintos modelos, con sus métricas de rendimiento. Se dedica también un apartado a la discusión crítica y a la interpretación de estos resultados en contextos tanto científico como tecnológico.
- El Capítulo 6 servirá para entender las conclusiones del estudio basándose en los resultados del capítulo 5, además de indicar las limitaciones del estudio y posibles líneas futuras de este.

## Capítulo 2: Objetivos del TFM

Este capítulo tiene como finalidad establecer las metas que guiarán el desarrollo del Trabajo de Fin de Máster. Se trata de constituir un itinerario definido que oriente la investigación desde la base teórica de las explicaciones

físicas hasta la obtención de los resultados mediante el uso de herramientas de inteligencia artificial.

La explicación de los objetivos pretende, por un lado, delimitar lo que se pretende lograr, y por otro, ofrecer un marco de referencia que asegure la coherencia en el trabajo. Se espera que el lector identifique de manera clara cual es el fin del proyecto, desde su base, su estructura y sus fases intermedias.

La delimitación de los objetivos en este campo es clave, dado que se trata de un campo que confluye la física, la astrofísica más concretamente, la ciencia de datos y el aprendizaje automático. Es imprescindible concretar metas realistas y útiles para el contexto científico-social. Primero se verá el objetivo general, resumiendo la finalidad del trabajo y le seguirán los objetivos específicos, que constituyen los pasos del desarrollo del mismo.

## 1. Objetivo general

- Desarrollar un modelo de predicción de la actividad solar extrema mediante el uso de observaciones satelitales y técnicas de aprendizaje profundo.

Se pretende construir y validar un modelo predictivo capaz de anticipar fenómenos solares extremos, fulguraciones y eyecciones de masa coronal, utilizando datos que proceden de satélites especializados.

## 2. Objetivos específicos

1. Revisar la literatura científica que se tiene para comprender los fundamentos físicos de las fulguraciones solares y eyecciones de masa coronal, así como estudiar los principales enfoques utilizados para la predicción de estos.

2. Limpiar, preprocesar y analizar los datos seleccionados. Los datos de los satélites SDO (Solar Dynamics Observatory), GOES (Geostationary Operational Environmental Satellites) o SOHO (Solar and Heliorpheric Observatory), por ejemplo, son satélites de los cuales se pretende obtener los datos, asegurar su calidad y adecuarlos para el entrenamiento de modelos predictivos.
3. Diseñar e implementar diferentes modelos predictivos, incluyendo enfoques tanto de redes neuronales recurrentes (LSTM), convolucionales (CNN) o otros, con el fin de ver las ventajas y limitaciones de cada uno. Mediante este punto se constituye una diversidad metodológica, lo que permitirá contrastar enfoques distintos.
4. Comparar el rendimiento de los modelos mediante métricas de evaluación estándar. Las métricas como la precisión, sensibilidad, especificidad y el área bajo la curva ROC o el F1-score son utilizadas para validar un modelo y comparar cual de los utilizados funciona mejor para el caso propuesto.
5. Aplicar los modelos a casos concretos como el Ciclo Solar 25, es decir, aplicarlo en un subconjunto de eventos significativos para estudiarlo y analizarlo con mayor detalle
6. Extraer conclusiones y proponer líneas futuras de estudio que permitan integrar de mejor manera la inteligencia artificial en esta área de la física.

Mediante estos objetivos se pretende tener una ruta clara con las metas a perseguir para cada apartado de manera clara y estructurada. Con esta

planificación, además de generar resultados académicos se espera aportar un valor añadido en el ámbito científico y tecnológico.

## Capítulo 3: Marco Teórico

El marco teórico es la base del Trabajo Fin de Máster. Es donde se analizan y se organizan los conocimientos necesarios para entender la naturaleza de los fenómenos que se pretenden estudiar, en nuestro caso, la actividad solar extrema y su predicción mediante inteligencia artificial. El fin de este capítulo es construir una base de conocimientos científicos sólida para poder justificar las decisiones metodológicas adoptadas en capítulos posteriores.

Hace ya siglos que se estudia la actividad solar de forma más o menos concreta, pero no es hasta la aparición de observatorios espaciales capaces de registrar la radiación electromagnética, el siglo XX, cuando se desarrolla su comprensión física de forma más íntegra. El sol es una fuente continua de energía electromagnética y de partículas cargadas, pero su comportamiento no es para nada constante, se rige principalmente por un ciclo de aproximadamente 11 años que alterna periodos de máxima y mínima actividad. Este ciclo afecta directamente a los fenómenos que estudiamos, como las fulguraciones solares y las eyecciones de masa coronal (CMEs), las cuales, como se ha comentado previamente, pueden tener consecuencias observables en La Tierra.

Comprender la física detrás de estos eventos requiere entender la estructura del Sol, los procesos que liberan enormes cantidades de energía, y la interacción entre el campo magnético del sol y el medio interplanetario. Luego se profundiza, pero principalmente las fulguraciones son explosiones de radiación electromagnética que ocurren en la corona solar, mientras que las CMEs consisten en la expulsión de plasma y campos magnéticos hacia el

espacio interplanetario. Ambos fenómenos están estrechamente relacionados. (Shibata & Magara, 2011; Chen 2011)

La relevancia de este tipo de investigaciones no se limita al ámbito académico. Los efectos de actividades solares pueden manifestarse en la tierra, como se ha mencionado ya, en forma de alteraciones en las comunicaciones por radio o errores en sistemas GPS.

En las últimas décadas se han aplicado nuevas herramientas al estudio de la actividad solar debido al avance de la computación y al desarrollo de nuevos métodos. Los modelos físicos más tradicionales basados en la magnetohidrodinámica (MHD), proporcionan una visión detallada de los procesos de la corona solar, pero son altamente complejos computacionalmente (Shibata & Magara, 2011). En este contexto, la inteligencia artificial ha emergido como una alternativa potencialmente prometedora para identificar patrones en grandes volúmenes de datos y así anticipar los fenómenos solares extremos.

Este capítulo aborda en detalle los fundamentos físicos de la actividad solar, las fulguraciones y las CMEs, la interacción entre los sucesos que ocurren en el sol y su repercusión en la Tierra, y finalmente, el estado del arte de las predicciones de este tipo de fenómenos mediante técnicas de inteligencia artificial.

### 3.1 Actividad solar y estructura del Sol

El sol es una estrella de tipo G2V, que constituye la fuente principal de energía del sistema solar y a la vez, un laboratorio natural para el estudio de la física del plasma. Su comportamiento, así como su estructura, determinan las condiciones del espacio interplanetario y, por ende, la meteorología espacial de la Tierra. Comprender su actividad requiere entender los procesos que ocurren en su superficie y atmósfera, responsables de las ya mencionadas fulguraciones y CMEs. (Chen, 2011; Shibata & Magara, 2011)



### 3.1.1 Estructura general del Sol

El sol puede dividirse en capas internas y externas, constituyendo una estructura estratificada. El núcleo, aproximadamente un cuarto del radio solar es donde tiene lugar la fusión nuclear del hidrógeno y el helio, un proceso que es capaz de liberar enormes cantidades de energía en forma de radiación gamma. La energía que se genera en el núcleo, tarda miles de años en alcanzar la superficie ya que atraviesa varias zonas que actúan como mecanismos de transporte: primero está la zona radiativa, donde se propaga por radiación. En esta zona los fotones son absorbidos y reemitidos incontables veces antes de avanzar, lo que hace que sea un proceso muy lento. Después se encuentra la zona convectiva, donde la temperatura baja lo suficiente para que el plasma empiece a moverse de forma turbulenta, como el agua hirviendo. Las burbujas de plasma ascienden, se enfrían, y descenden, siendo este el artífice de la creación del campo magnético solar. (NASA, 2024) (Priest & Forbes, 2002)

La capa visible de llama fotosfera, es la región que percibimos desde la Tierra. Tiene unas temperaturas de unos  $5.500^{\circ}\text{C}$ , y en ella se observan manchas solares, zonas más frías (unos  $3000\text{-}4000^{\circ}\text{C}$ ) donde el campo magnético es más intenso. Estas manchas son uno de los indicadores que más se utilizan para determinar el nivel de actividad solar (Howard et al., 2023)

Por encima de la fotosfera está la cromosfera, una capa delgada donde se llegan a temperaturas de entre  $10.000$  y  $100.000^{\circ}\text{C}$ . En esta capa se producen espículos y protuberancias solares, fenómenos que consisten en filamentos de plasma que pueden extenderse miles de kilómetros hacia el espacio.

Y finalmente, en los exteriores se encuentra la corona solar, una envoltura extremadamente caliente y tenue que, a pesar de estar alejada del núcleo, puede llegar a alcanzar los millones de grados. Este aumento de temperatura sigue siendo uno de los misterios a resolver de la astrofísica moderna debido a su contrariedad (Shibata & Magara, 2011). Esta parte del sol es visible

desde la Tierra durante eclipses solares o mediante instrumentos especializados como los cronógrafos de satélites como SOHO y SDO, gracias a los cuales la corona solar se ha podido estudiar con mayor detalle.

Todo el conjunto solar, desde el núcleo hasta la corona, está compuesto por plasma. El plasma es un estado de la materia formado por partículas cargadas eléctricamente, que, al moverse, genera y transporta campos magnéticos. Esto convierte al Sol en un sistema enormemente complejo, capaz de liberar grandes cantidades de energía en periodos cortos. Como señalan Shibata y Magara (2011), “el comportamiento del Sol se rige por la interacción constante entre el plasma y los campos magnéticos, una combinación que da lugar a fenómenos de gran intensidad que pueden tener efectos detectables incluso a millones de kilómetros de distancia”.

Entendiendo la física detrás de todo esto, se abordará con mayor entendimiento los procesos de sus capas más activas como las fulguraciones solares y las eyecciones de masa coronal (CMEs).

### 3.1.2 Campo magnético solar y ciclo de actividad

El comportamiento del Sol, lejos de ser constante, varía de forma periódica debido al campo magnético. Este campo magnético es el responsable de todos los fenómenos que se denominan como “actividad solar”, fenómenos como las fulguraciones, las CMEs o las tormentas solares. Su estudio y entendimiento es clave para entender el funcionamiento del sol y para anticipar estos fenómenos que pueden afectar a la Tierra de manera directa. (Chen, 2011; Howard et al., 2023).

El campo magnético se genera debido a que el Sol funciona como un gran generador electromagnético, a causa de su rotación y convección, y los movimientos del plasma (que está cargado eléctricamente) en su interior producen campos magnéticos (Priest & Forbes, 2022). La rotación es un factor clave en el proceso ya que, a diferencia de la Tierra, el Sol no es sólido y su

velocidad de rotación varía según la latitud: el ecuador completa la rotación en unos 25 días y las regiones polares tardan alrededor de 35. Estas diferencias retuercen las líneas de campo, y por ende, acumulan energía y favorecen liberaciones de grandes energías en forma de radiación o liberación de plasma. (Shibata & Magara, 2011)

La configuración del campo magnético del Sol cambia a lo largo del tiempo, siguiendo un patrón que se conoce como el ciclo solar. Este ciclo tiene una duración de aproximadamente 11 años, puede variar entre 9 y 14. Durante el periodo de un ciclo, las manchas solares (regiones donde el campo magnético es muy intenso) oscilan entre el máximo y el mínimo. En cada ciclo, los polos magnéticos del Sol se invierten, convirtiendo el polo norte en sur y viceversa. Por lógica, entonces, se puede decir que un ciclo magnético dura aproximadamente 22 años, dos ciclos solares. (NASA, 2024)

El ciclo solar afecta a la cantidad de fulguraciones y CMEs que se producen. En máximos en términos de actividad, además de haber más fenómenos, los que hay son mucho más energéticos, incrementando el riesgo de alteraciones en la magnetosfera terrestre y los sistemas tecnológicos que dependen de ella. (Green & Baker, 2015)

El seguimiento del ciclo se hace mediante distintos indicadores observacionales. El más utilizado es el número de manchas solares (Sunspot Number), que se calcula a partir de observaciones diarias desde hace 400 años. Otro índice que se utiliza también como referencia en varios modelos de predicción es el F10.7, que mide el flujo de radiación en una longitud de onda, el radio.

Actualmente el Sol se encuentra en el Ciclo Solar 25, iniciado de manera oficial en 2019. Se preveía un ciclo moderado, pero las observaciones recientes de la NASA y la NOAA desvelan que está superando las expectativas, siendo más activo de lo esperado con más manchas solares de lo predicho. Durante

2024 y 2025 se han registrado numerosos eventos de clase X, los más intensos, lo que confirma una fase de máxima actividad. (NASA, 2024)

## 3.2 Fenómenos asociados a la actividad solar

Como se ha mencionado en los apartados previos, la actividad solar se manifiesta a través de una serie de fenómenos. Entre los fenómenos más relevantes se encuentran las fulguraciones solares y las CMEs, las expresiones más violentas y visibles de la actividad solar. Ambos eventos están relacionados directamente con el campo magnético, específicamente con un proceso que rompe las líneas de campo y las reorganiza liberando enormes cantidades de energía, la reconexión magnética. Esta energía, que se acumula durante días o semanas, es liberada en minutos o incluso segundos, generando radiación, partículas altamente energéticas y ondas que se propagan a través del sistema solar. (Shibata & Magara, 2011)

Las fulguraciones y CMEs se pueden producir de forma simultánea o independiente, dependiendo de la configuración del campo magnético y la corona, pero el principio físico que rige ambos fenómenos es el mismo: la conversión de energía magnética en energía cinética, térmica y radiativa. (Priest & Forbes, 2002)

En este apartado se explica en detalle la física detrás de estos fenómenos, así como sus consecuencias más relevantes para la Tierra.

### 3.2.1 Fulguraciones solares

Las fulguraciones solares son explosiones de energía que suceden en la atmósfera del sol. Las fulguraciones son causa de que las líneas de campo que se habían comprimido se rompan y se reorganicen en una configuración más estable. Este proceso libera una cantidad de energía gigantesca, equivalente a millones de bombas de hidrógeno, en apenas minutos (Priest & Forbes,

2002). Durante una fulguración, la energía magnética que ha sido almacenada se libera, el material se calienta y las partículas son aceleradas a velocidades relativistas generando radiación electromagnética en todo el espectro. (Shibata & Magara, 2011).

La intensidad de estos fenómenos se mide por la cantidad de radiación detectada en los satélites GOES (Geostationary Operational Environmental Satellite). Se explica el sistema en la Tabla 1.

*Tabla 1: Sistema de clasificación de las fulguraciones solares por su intensidad.*

| Clase    | Intensidad de flujo ( $W/m^2$ ) | Descripción general     |
|----------|---------------------------------|-------------------------|
| <b>A</b> | $< 10^{-7}$                     | Actividad solar mínima  |
| <b>B</b> | $10^{-7} - 10^{-6}$             | Fulguraciones débiles   |
| <b>C</b> | $10^{-6} - 10^{-5}$             | Fulguraciones moderadas |
| <b>M</b> | $10^{-5} - 10^{-4}$             | Fulguraciones fuertes   |
| <b>X</b> | $> 10^{-4}$                     | Fulguraciones extremas  |

Las de tipo M y X son frecuentes cuando el Sol esta en actividades máximas, por ejemplo, en 2017 se registró una fulguración de clase X9.3 que provocó interrupciones temporales en el Atlántico.

A diferencia de los CMEs, las fulguraciones no expulsan materia hacia el espacio, solo radiación electromagnética y partículas energéticas, las cuales pueden causar efectos como apagones de radio, alteraciones en señales GPS... Estos pueden sentirse rápidamente en la Tierra, en cuestión de minutos, ya que la radiación electromagnética viaja a la velocidad de la luz.

En conjunto, las fulguraciones representan la manifestación más inmediata y visible de la actividad extrema solar. Son eventos rápidos, muy energéticos y con una gran influencia en la radiación solar.

### 3.2.2 Eyecciones de masa coronal (CMEs)

Las eyecciones de masa coronal (CMEs, por sus siglas en inglés) son inmensas erupciones de plasma y campos magnéticos que se desprenden del Sol, específicamente de la corona, y viajan hacia el espacio. Son las principales causantes de las tormentas geomagnéticas que afectan a la Tierra ya que son de los fenómenos más energéticos que pueden darse en el sistema solar. (Howard et al., 2023)


Durante una CME una burbuja pesada de plasma es expulsada hacia el espacio a gran velocidad. En los CMEs más energéticos se puede liberar una energía de hasta  $10^{32}$  *ergios*, que equivalen a miles de millones de bombas atómicas. Estos procesos llevan consigo parte del campo magnético y dependiendo sus características, actuarán de forma más o menos intensa con la magnetosfera terrestre. (Green & Baker, 2015)

Al igual que las fulguraciones, se forman en la corona, cuando las líneas de campo acumulan energía durante un periodo y al reconfigurarse, liberan esa energía acumulada en un periodo corto de tiempo. En muchos casos, de hecho, las CMEs están asociadas a las fulguraciones, ocurriendo en el mismo lugar, aunque no siempre. A veces no hay expulsión de masa y solo fulguraciones, y a veces hay CMEs independientes, dependiendo del campo magnético. (Priest & Forbes, 2002)

Mediante observadores como antiguamente SOHO (Solar and Heliospheric Observatory) y ahora SDO (Solar Dynamics Observatory), se ha podido estudiar estos eventos en detalle. Las CMEs suelen presentar una de las tres estructuras siguientes:

1. Un frente brillante, que corresponde a material comprimido del viento solar
2. Una cavidad oscura, que representa el campo magnético expandido.
3. Un núcleo brillante, asociado a una prominencia solar expulsada.

*Figura 3: Representación visual de las tres partes de un CME.  
(SOHO, 2002)*



Una vez se expulsa la materia se propaga a través del viento solar (un flujo de partículas cargadas) interactuando con el campo magnético interplanetario. El tiempo que tarda en llegar una CME a tierra es de unas 15 a 18 horas.

Las CMEs son los fenómenos más relevantes en la meteorología espacial extrema. Cuando impactan en la tierra pueden inducir corrientes geomagnéticas causando daños como alterar comunicaciones por satélite o sistemas GPS. Un ejemplo de esto es la tormenta de Quebec en 1989, causada

por una CME muy energética, que dejó sin suministro a millones de personas durante 9 horas (Boteler, 2019).

Estos casos muestran la importancia de predecir de manera precisa y veloz los fenómenos fruto de la actividad solar extrema, que no son únicamente fenómenos astronómicos, sino que pueden tener repercusión directa en la infraestructura tecnológica.

### 3.2.3 Consecuencias en la Tierra y el entorno espacial

Las partículas cargadas que son liberadas por el Sol, así como el campo magnético, al alcanzar nuestro planeta producen tormentas geomagnéticas. La magnetosfera terrestre actúa como escudo natural frente al flujo de estas partículas cargadas. Sin embargo, cuando el campo que impacta está orientado de manera opuesta al campo terrestre, permite la entrada de partículas cargadas y energía, generando fluctuaciones en el campo magnético terrestre y corrientes inducidas que alteran redes eléctricas y de comunicación. Las GIC (corrientes geomagnéticas inducidas, por sus siglas en inglés) pueden causar desde colapsos en la red eléctrica hasta dañar satélites y misiones espaciales.

Además de las consecuencias en la infraestructura tecnológica, pueden manifestarse de forma natural, mediante auroras polares. Estas se producen cuando las partículas cargadas que llegan desde el Sol excitan los átomos de oxígeno y nitrógeno de la atmósfera, y al relajarse liberan fotones (luz visible, lo que vemos).

Hoy en día, la meteorología espacial combina la física y las observaciones para anticiparse a eventos y predecir estas tormentas y su impacto. Satélites como SOHO, ACE o DSCOVR permiten vigilar el viento solar y el campo magnético a tiempo real. Aun con todo esto, la predicción sigue siendo un desafío por sus varias variantes como la dirección e intensidad del viento, lo que ha



impulsado al uso de nuevas herramientas como la inteligencia artificial para mejorar esos resultados y dar respuestas más veloces.

### 3.3 Predicción de la actividad solar: del modelo físico a la inteligencia artificial

La predicción de los fenómenos solares sigue siendo un reto mayúsculo. Saber cuando ocurrirá una fulguración o una CME y cuan intensa será es un desafío difícil de superar por ahora. Su complejidad, la naturaleza no lineal y el carácter caótico de estos procesos naturales hacen que los modelos puramente teóricos no sean suficiente, por ello se esta integrando cada vez mas herramientas de aprendizaje automático y aprendizaje profundo para mejorar estas predicciones.

#### 3.3.1 Modelos tradicionales

Los primeros modelos utilizados para la predicción fueron modelos estadísticos que buscaban correlaciones entre el número de manchas, flujos de radiación y frecuencia de fulguraciones y CMEs. Estos modelos tenían una fuerte dependencia hacia la calidad de los datos, y no captaban del todo la complejidad del sistema solar. (Shibata & Magara, 2011)

Mas tarde surgió la magnetohidrodinámica (MHD), que trata al plasma solar como un fluido conductor de campos magnéticos. Estos modelos son capaces de reproducir la formación y propagación de las CMEs, sin embargo, conllevan una alta demanda computacional y la necesidad de condiciones concretas y precisas, difícilmente alcanzables. (Priest y Forbes, 2002)

Paralelamente a la magnetohidrodinámica, se han ido desarrollando modelos temporales, utilizando técnicas como los modelos ARIMA y SARIMA para tratar de describir la periodicidad del ciclo solar. Estos modelos, al ser lineales, pueden ser útiles a corto plazo, pero su rendimiento disminuye de

manera importante cuando tratan de captar la naturaleza no lineal y algo caótica de las fulguraciones o CMEs.

Básicamente, los modelos más tradicionales presentan limitaciones como escasa adaptabilidad ante condiciones no fijas, dependencia de parámetros difíciles de medir y alta carga computacional. Estas limitaciones han incitado a los científicos a explorar nuevas herramientas como la inteligencia artificial, capaces de aprender de los datos y detectar patrones muy complejos.

### 3.3.2 Inteligencia artificial aplicada a la predicción solar

El uso de la inteligencia artificial en la investigación solar ha crecido de manera exponencial en la última década, impulsado por la gran cantidad de datos procedentes de satélites como SDO, SOHO o GOES. Estos satélites generan grandes cantidades de información diaria, carne de cañón para aplicar técnicas de machine learning y Deep learning.

Las principales aplicaciones de IA incluyen:

- Clasificación de fulguraciones dependiendo de su intensidad mediante CNN.
- Predicción de CMEs utilizando modelos supervisados entrenados con imágenes del SDO.
- Análisis de series temporales (por ejemplo, el flujo de rayos X de GOES) con redes neuronales recurrentes (RNN y LSTM) para detectar patrones a eventos extremos
- Modelos híbridos que combinan MHD con aprendizaje profundo.

Un ejemplo es el trabajo de la NASA y NOAA, que utilizan IA para automatizar la detección de regiones activas y estimar la probabilidad de erupción.

La principal ventaja de estos modelos radica en la capacidad de aprender relaciones no lineales entre variables, sin modelar las ecuaciones físicas. Pero no todo son cosas positivas, estos modelos tienen también desafíos como su explicabilidad o la dependencia de datos de calidad, por lo que hay que tener cuidado con el manejo de los datos.

### 3.3.3 Estado del arte

En los últimos años, el uso de la IA a la predicción de la actividad solar ha experimentado un crecimiento notable. El hecho de que hay grandes bases de datos disponibles de misiones como SDO, SOHO o GOES facilita el auge de estas nuevas herramientas. Sin embargo, el campo de estudio sigue encontrándose con desafíos continuos como la interpretabilidad, la generalización de modelos o la escasez de datos en el campo.

Se destacan a continuación algunos de los trabajos más representativos que marcan la evolución del estado del arte:

- *Predicción de fulguraciones mediante aprendizaje profundo (Wang et al., 2024)*

Un estudio reciente propone un enfoque que se basa en redes convolucionales (CNN) para predecir fulguraciones utilizando imágenes de regiones activas captadas por SDO. El modelo fue capaz de anticipar fulguraciones de clase M y X con una precisión mayor del 85% hasta 24 horas antes de que ocurran. Este trabajo destaca la capacidad de aprendizaje profundo para reconocer patrones espaciales complejos e integrarlo a información del campo magnético.

- *Modelos explicables para predicción de tormentas solares (Santos et al., 2025)*

Uno de los avances más importantes de los últimos años es la introducción de la inteligencia artificial explicable (XAI) en el ámbito solar. En este trabajo se aplican técnicas de interpretabilidad a redes LSTM diseñadas para predecir tormentas solares a partir de series temporales de flujo de rayos X y viento solar. No solo se logra una precisión del 82%, sino que además se identifican mediante XAI que variables tienen mayor influencia en cada predicción, aumentando la transparencia.

- *Predicción de CMEs geoeffectivas con imágenes coronográficas (Liu et al., 2024)*

En el ámbito de CMEs, este trabajo destaca por el uso de imágenes del satélite SOHO como entrada directa a una red neuronal convolucional. El modelo predice si una CME impactará la Tierra (que sea geoefectiva) con un índice de correlación de Matthews de 0,81 y una TSS de 0,71, superando los modelos tradicionales.

- *Integración de IA multimodal en meteorología espacial (NASA, 2024)*

Un enfoque emergente es la combinación de varias fuentes de datos en modelos a gran escala. NASA y IBM han desarrollado Surya, un modelo de IA entrenado con datos del SDO que predice fulguraciones y genera visualizaciones interpretables del riesgo solar. El aumento del modelo ha subido un 16% al de los modelos previos y realiza predicciones visuales con hasta 2 horas de antelación.

- *Predicción detallada de fulguraciones mediante redes híbridas CNN-GAN (Deng et al., 2021)*

En este trabajo se propone un modelo híbrido basado en redes convolucionales y generativas (CNN-GAN) aplicado a magnetogramas del instrumento HMI del satélite SDO. Este enfoque permite identificar estructuras magnéticas asociadas a fulguraciones de diferentes intensidades (C, M y X). Los resultados superan los modelos tradicionales y destacan la capacidad del aprendizaje profundo para captar la complejidad del campo magnético del sol

Los estudios recientes muestran un cambio en el paradigma de la predicción solar. Los modelos ya no se limitan a describir el comportamiento del Sol, sino que aprenden de los datos adaptándose a su complejidad no lineal. A pesar de esto, aun hay muchos desafíos que parten de ampliar la base de datos, aumentar la interpretabilidad y fusionar el mundo de la física y el de la IA para predicciones más precisas.

## Capítulo 4: Marco Metodológico

En este capítulo se describe el procedimiento que ha llevado al desarrollo del proyecto de investigación, el cual pretende construir modelos de predicción de actividad solar extrema, específicamente fulguraciones solares y eyecciones de masa coronal (CMEs), mediante técnicas de aprendizaje profundo. Se ha realizado un trabajo para integrar observaciones satelitales preprocesadas a modelos neuronales tipo LSTM (long-short term memory) y CNN unidimensional (Convolutional Neural Network), arquitecturas que se utilizan en la modelización de series temporales y que detectan patrones especialmente complejos. (Hochreiter & Schmidhuber, 1997; LeCun et al., 2015) Esta investigación tiene un carácter cuantitativo, analítico y experimental. Se apoya en la minería de datos y en la modelización predictiva mediante inteligencia artificial. Nace de una necesidad científica como la

dificultad de anticipar fenómenos astronómicos, solares en este caso, de alta energía por su naturaleza caótica y no lineal. Este problema se aborda mediante el análisis de grandes volúmenes de datos de observaciones satelitales reales, y combina el conocimiento físico del problema con herramientas de inteligencia artificial capaces de detectar patrones en grandes volúmenes de datos.

Para ello, se han utilizado fuentes de datos públicas y confiables de agencias espaciales internacionales como NOAA (National Oceanic and Atmospheric Administration), NASA (National Aeronautics and Space Administration) y ESA (European Space Agency), que son las responsables de poner a disposición datos de observaciones de los satélites GOES (Geostationary Operational Environmental Satellite) el cual mide flujos de rayos X y contiene eventos etiquetados como fulguraciones, SDO/HMI-SHARP (Solar Dynamics Observatory) el cual mide parámetros magnéticos y SOHO/LASCO (Solar and Heliospheric Observatory) que contiene un catálogo de CMEs. Estas fuentes de datos constituyen un estándar de referencia en heliofísica (NASA, 2024).


A partir de las fuentes mencionadas, se ha construido una base de datos conjunta para cada caso. En primer lugar, se ha desarrollado un modelo orientado a la predicción de fulguraciones de tipo M o X. Para ello se han utilizado datos del satélite GOES 18 de la NOAA, que proporcionan intensidades del flujo de rayos X y un catálogo de fulguraciones de distintas clases. Estos datos organizados, permiten caracterizar la evolución temporal del flujo y establecer patrones previos a una fulguración de tipo M o X (las más energéticas).

En segundo lugar, se ha implementado un modelo para la predicción de eyecciones de masa coronal más energéticas. Para ello se han combinado parámetros magnéticos obtenidos a partir del satélite SDO/HMI (NASA) con eventos catalogados como CME de SOHO/LASCO (ESA/NASA). Estos parámetros describen la configuración y complejidad del campo magnético solar.

Ambos diseños comparten el uso de modelos de aprendizaje profundo, redes LSTM y CNN 1D, entrenados y evaluados mediante Python y las librerías TensorFlow/Keras, NumPy y Pandas. Las métricas de evaluación, tales como la precisión, sensibilidad, especificidad o AUROC, se han calculado de forma independiente para cada caso, con el fin de comparar los comportamientos predictivos y las capacidades de cada modelo para generalizar.

El capítulo se estructura en distintos apartados. Primero se define la población y muestra utilizadas, donde se explican los criterios de selección. A continuación, se detallan las variables intervinientes y los instrumentos de recogida y análisis de datos. Sigue con la descripción del diseño, donde explica la naturaleza de los modelos y el procedimiento que se ha utilizado para su entrenamiento y validación. Finalmente, se expone el modelo final, detallando las métricas utilizadas y métodos para su interpretación.

*Figura 4: Observatorio SDO (arriba a la izquierda), satélite SOHO (arriba a la derecha) y satélite GOES (abajo). (NASA)*





## 4.1 Población y muestra

La población es formada por observaciones satelitales constituido por los satélites GOES-18 (NOAA), SDO/HMI (NASA) y SOHO/LASCO (ESA/NASA). Estas misiones proporcionan medidas de fenómenos eruptivos del Sol: GOES-18 registra el flujo de rayos X emitido, mientras que SDO y SOHO miden los parámetros de propiedades magnéticas y permiten clasificar las CMEs.

La primera parte, centrada en la predicción de fulguraciones de tipo M y X, se limita a las observaciones de rayos X registradas por el satélite GOES-18 durante el año actual, 2025, en resolución de 1 minuto. Los archivos empleados (`sci_xrsf-l2-avg1m_g18_y2025_v2-2-0.nc` y `sci_xrsf-l2-flsum_g18_s20220810_e20251012_v2-2-0.nc`) contienen valores del flujo de rayos X en las bandas de 0.1-0.8 nm y 0.05 y 0.4 nm, los cuales permiten caracterizar la evolución temporal de la emisión solar. Según Priest & Forbes, 2002, la intensidad del flujo de rayos X es un indicador directo de la liberación de energía durante una fulguración, por lo que estos datos constituyen una referencia para el análisis de fulguraciones de tipo M y X. El rango temporal seleccionado abarca un año completo con datos continuos, lo que proporciona estabilidad al modelo.

En el caso de las eyecciones de masa coronal, la muestra es algo más compleja. Es formada por un catálogo del observatorio SOHO/LASCO de CMEs desde el año 1996 hasta el 2025, y este catalogo se combina con parámetros magnéticos obtenidos a partir de datos de SHARP del satélite SDO/HMI que tiene datos desde 2022 hasta 2025, distribuidos públicamente. El conjunto incluye variables como USFLUX (Flujo magnético total en la superficie), TOTPOT (energía libre total en el campo), MEANGAM (ángulo medio entre el vector del campo y la dirección radial del sol) entre otras. Se han unido estos conjuntos de datos en uno solo de un rango temporal de 2022 a 2025, lo que ha permitido vincular el catálogo de CMEs con indicadores del potencial eruptivo de las regiones activas del sol. La elección de CMEs a predecir se ha realizado mediante umbrales en los valores de velocidad y anchura angular.



En ambos estudios se ha llevado a cabo un proceso de limpieza y sincronización temporal de los datos, limpiándolos y ajustando las escalas temporales para que coincidiesen. Posteriormente se ha realizado la división de conjuntos de entrenamiento, validación y prueba, garantizando que fueran independientes y evitando solapamientos, para así tener tres conjuntos representativos y fiables en ambos casos.

## 4.2 Variables intervinientes e instrumentos de evaluación

En ambos casos del trabajo, tanto en las fulguraciones como en las CMEs, se han definido variables dependientes e independientes, las cuales permiten la construcción de los modelos predictivos mediante redes neuronales profundas.

- Fulguraciones solares (GOES-18)

Para el primer caso, la variable dependiente corresponde a la ocurrencia o no de un evento de tipo M o X (muy energético). Esta variable se ha determinado a partir de los picos de rayos X registradas en el satélite GOES-18. La variable independiente se compone de las series temporales del flujo de radiación solar medidas, descriptoras de la emisión del sol a lo largo del tiempo. El instrumento con el que se ha medido la variable es el sensor XRS (x-ray sensor) a bordo del satélite GOES. De este modo, las variaciones del flujo de rayos X pueden dar información sobre eventos altamente energéticos previos a su erupción.

- Eyecciones de masa coronal (CMEs)

Para el caso de CMEs, la variable dependiente corresponde a la ocurrencia de una CME energética, definida según la velocidad de propagación y anchura

angular de esta. Las variables independientes corresponden a los parámetros magnéticos extraídos del conjunto SHARP, derivados del instrumento HMI del satélite SDO. El conjunto de datos distribuido por el repositorio Zenodo públicamente, incluye variables como:

USFLUX: Cantidad total del campo magnético que atraviesa la superficie activa.

TOTPOT: Energía libre total del campo magnético.

MEANGAM: Ángulo medio entre el campo magnético y la superficie del sol.

TOTUSJZ: Densidad de corriente que sube o baja del Sol.

R\_VALUE: Cantidad de flujo justo donde cambia la polaridad (norte-sur)

Estas variables describen la complejidad del campo magnético en las regiones activas del sol y son factores relacionados con la inestabilidad que genera las CMEs (Bobra et al., 2014). Estos parámetros han sido unificados con el catálogo de CMEs de SOHO/LASCO, que proporciona información como la velocidad, anchura angular y aceleración de cada evento.

Ambos casos, tanto las fulguraciones como CMEs han sido estructurados en series temporales normalizadas empleadas para el entrenamiento de modelos LSTM y CNN 1D, orientados a detectar patrones no lineales y dependencias temporales.

Para ambos fenómenos se han utilizado las mismas métricas de evaluación, tales como la precisión, sensibilidad o recall, F1-score y AUROC (Área bajo la curva ROC). Estas métricas permiten evaluar tanto la capacidad del modelo de detectar positivos (fulguraciones tipo M o X y CMEs energéticas), como el equilibrio de este frente a falsos positivos, aspecto muy importante en problemas con clases desbalanceadas.

### 4.3 Diseño experimental

El diseño del trabajo, como el resto, se estructura en dos bloques, aunque ambos comparten la misma metodología general. Tanto para las fulguraciones como para las CMEs, se han recopilado los datos, preprocesado, generado secuencias temporales, dividido en subconjuntos de entrenamiento, validación y prueba y finalmente se ha construido los modelos de aprendizaje profundo con un enfoque cuantitativo.

Para la adquisición de datos se han recopilado observaciones satelitales de fuentes públicas como NOAA, NASA y ESA. Los datos de fulguraciones se obtuvieron del satélite GOES-18, mediante archivos csv. Uno de los archivos era un catálogo de fulguraciones y el otro flujo de rayos X en intervalos de 1 minuto. Lo relativo a las CMEs a través de SOHO se obtuvo el catálogo en un csv y mediante el repositorio Zenodo a través de un archivo comprimido se obtuvo los parámetros magnéticos detectados por SDO/HM.

A todos esos archivos se les han aplicado procesos de limpieza para eliminar duplicados o incompletos y se han estandarizado las escalas temporales. En el caso de CMEs, los parámetros se han reorganizado, alineándolo con el catálogo de CMEs, tras la cual se han normalizado los valores numéricos para garantizar el rango de magnitud y evitar sesgos.

Con el fin de adaptar los datos a modelos secuenciales, se han transformado series continuas en ventanas deslizantes de longitud fija. Cada ventana representa un intervalo temporal previo al evento objetivo, de modo que pudiera aprender patrones temporales que preceden al suceso. Para garantizar la independencia de los subconjuntos y evitar fugas, se ha dividido los datos de forma temporal en 3 conjuntos: entrenamiento, validación y prueba, con un 70%, 15% y 15% respectivamente. Esta separación temporal asegura que los modelos evalúen sobre observaciones posteriores al entrenamiento, así se simula un escenario real.

Para ambos casos se han implementado dos tipos de arquitecturas:

- Red LSTM (Long Short-Term Memory)

Las redes LSTM son una extensión de las redes neuronales recurrentes (RNN) que están diseñados para aprender dependencias a largo plazo en secuencias temporales. A diferencia de los RNN típicas, las LSTM tienen celdas de memoria y puertas de control que permiten decidir qué información conservan y cual descartan mediante el procesamiento de la secuencia. Gracias a esto, pueden recordar patrones que han ocurrido muchas etapas atrás, evitando el problema del desvanecimiento del gradiente típico de las RNN convencionales. (Hochreiter S. & Schmidhuber J., 1997)

En el trabajo, las LSTM se han utilizado para modelar la evolución temporal del flujo de rayos X para el caso de fulguraciones, y de parámetros magnéticos para el caso de CMEs, buscando patrones que anticipen un evento energético. Se aplicaron mecanismos como Early Stopping para detener el entrenamiento cuando la validación dejaba de mejorar e incluye capas densas con funciones de activación sigmoide para realizar una clasificación binaria (evento / no evento).

- Red CNN 1D (Convolutional Neural Network unidimensional)

Las redes CNN son arquitecturas diseñadas para el análisis de imágenes, pero pueden adaptarse a series temporales en su versión unidimensional. En lugar de píxeles, utiliza filtros convolucionales que se deslizan sobre la secuencia temporal y detecta patrones locales (LeCun et al., 2015). Estas redes son especialmente útiles para detectar picos o gradientes bruscos.

En el caso del trabajo, se ha aplicado un CNN 1D a ambos modelos. Constan de varias capas convolucionales y de pooling, seguidas de una capa densa final. Esta configuración ha permitido extraer características espaciales y

temporales sin necesidad de una memoria explícita como en LSTM, lo que lo hace más ligero y rápido de entrenar.

Evidentemente, ambos modelos se han utilizado con las mismas condiciones experimentales, con los mismos conjuntos de datos y métricas para maximizar su equilibrio. Durante el entrenamiento se han aplicado también técnicas de balanceo de clases debido al número reducido de eventos energéticos respecto a los no energéticos.

El desempeño de cada modelo se ha evaluado mediante métricas como la precisión, la sensibilidad o recall, F1-score o el área bajo la curva AUROC. Se han considerado las mejores métricas por ofrecer una evaluación completa en un contexto como el nuestro, donde hay un desbalance de clases significativo.

El desarrollo completo se ha realizado en un entorno controlado con versiones documentadas de las librerías utilizadas. Se han almacenado en dos cuadernos separados, por lo que cada notebook conserva los hiperparámetros, configuraciones y métricas de salida, permitiendo replicar los resultados y verificar la trazabilidad del proceso entero.

## 4.4 Modelo de análisis de datos

El análisis de los resultados se basa en la evaluación cuantitativa del rendimiento de cada modelo desarrollado para ambos fenómenos de actividad solar extrema. Ambos casos son problemas de clasificación binaria con clases desbalanceadas (eventos energéticos vs no energéticos), por tanto, el enfoque de la evaluación se ha diseñado para priorizar la detección de la clase minoritaria (fulguraciones de tipo M/X y CMEs energéticas), evitando excesiva pérdida en la precisión y balanceando los modelos.

#### 4.4.1 Métricas de rendimiento

El comportamiento de los modelos se evalúa mediante métricas ampliamente utilizadas en inteligencia artificial aplicada a predicción de eventos poco frecuentes. (Santos et al. 2025)

Las métricas principales son:

- Precisión: La proporción de verdaderos positivos sobre el total de predicciones positivas. Mide la fiabilidad de las predicciones positivas del modelo.

$$Precision = \frac{TP}{TP + FP}$$

- Sensibilidad o Recall: La proporción de verdaderos positivos detectados respecto al total de eventos reales. Evalúa la capacidad del modelo para no dejar escapar un fenómeno real, en este trabajo es la métrica más importante ya que lo que busca es detectar los eventos altamente energéticos.

$$Recall = \frac{TP}{TP + FN}$$

- F1-score: La media armónica entre precisión y recall. Proporciona una visión del rendimiento global del modelo, muy útil para el trabajo ya que las clases están desbalanceadas.

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- AUROC (Área bajo la curva ROC): Mide la capacidad global del modelo para discriminar entre clases positivas y negativas sin depender de un umbral fijo. Un valor de 1 es una separación perfecta y 0.5 es azar.

Estas métricas son las indicadoras del comportamiento y capacidad de generalización del modelo, tanto en el conjunto de validación como en el de prueba.

Cada modelo se ha entrenado con dos arquitecturas independientes, un LSTM y un CNN 1D. Los resultados se analizan de manera comparativa valorando las métricas principales mencionadas anteriormente. De esta manera se puede determinar que arquitectura ofrece un comportamiento más estable y adecuado para cada tipo de dato.

#### 4.4.2 Criterios de interpretación y validez

En el contexto de este trabajo, además de los valores numéricos como las métricas se valora la coherencia, estabilidad y patrones aprendidos de los modelos. El análisis incluye una perspectiva explicativa y comparativa que busca determinar si las arquitecturas utilizadas son capaces de reconocer relaciones temporales o magnetográficas consistentes en un entorno real como el de los fenómenos solares.

Se considera que un modelo es válido cuando las predicciones reflejan una tendencia clara en la separación de clases, con valores AUROC elevados, lo que sería una evidencia de que el sistema ha aprendido una estructura interna de los datos.

Asimismo, la coherencia entre los conjuntos de validación y prueba son puntos importantes donde fijarse para determinar la estabilidad y capacidad de generalización del modelo. Una diferencia significativa entre ambas se interpreta como sobreajuste, restando fiabilidad a los resultados. De la misma

forma, se analizan los valores numéricos de las métricas ya mencionadas, buscando principalmente que el modelo sea capaz de detectar la mayor proporción posible de eventos positivos sin comprometer de manera excesiva la fiabilidad de los resultados. Este equilibrio, F1-score, resulta especialmente importante en este contexto debido al desbalanceo de clases.

También se debe tener en cuenta la interpretación física de los resultados. Debe tenerse en cuenta que no todos los eventos presentan necesariamente patrones detectables previos a su aparición. En el contexto de este trabajo, en el caso de las fulguraciones, la liberación de energía suele ir precedida de una acumulación observable en el flujo de rayos X, por lo que tendría sentido captar patrones previos a estos eventos. Sin embargo, para el caso de las eyecciones de masa coronal, pueden desencadenarse debido a procesos internos solares, por lo que la falta de datos de parámetros observados antes del evento puede ser una limitación importante debido a este carácter impredecible y caótico. Este carácter explica que, incluso con técnicas avanzadas de inteligencia artificial, los modelos puedan mostrar grandes limitaciones para distinguir las diferentes clases sin que implique un fallo metodológico importante, sino una ausencia de información previa suficiente en los datos disponibles.

El análisis de métricas cuantitativas se complementa con una discusión crítica en el apartado de Resultados, donde se interpretan los contextos físicos, la naturaleza de los datos y las limitaciones de estos, así como de las arquitecturas utilizadas.

## Capítulo 5: Presentación de análisis, resultados y discusión

Este capítulo recoge los resultados obtenidos tras el análisis de datos y aplicar los modelos desarrollados para ambos eventos. Para comenzar, se expone la



caracterización de la muestra y las condiciones bajo las que se llevó a cabo el trabajo a nivel computacional, el cual incluye la selección, limpieza y combinación de registros observacionales tanto para las fulguraciones de tipo M o X como para las CMEs energéticas. Se presentan así, los resultados obtenidos derivados de la experimentación de los modelos de redes neuronales aplicados, LSTM y CNN, evaluados mediante las métricas de precisión, susceptibilidad o recall, F1-score y el área bajo la curva ROC.

También en este apartado se discute la coherencia científica y las posibles implicaciones de estas predicciones, analizando tanto los aciertos como las limitaciones y posibles puntos de mejora de los modelos.

## 5.1 Análisis descriptivo de la muestra

Previo a examinar los resultados numéricos del modelo, conviene detenerse en la caracterización de las muestras sobre la que se han construido los modelos. Más allá de la descripción de técnicas de obtención de datos y preprocesamiento, se busca tener una visión completa del conjunto con el que se ha trabajado, teniendo en cuenta patrones, distribución temporal y frecuencia de eventos. Con esto no se quiere decir que los resultados no tengan validez, sino que hay que contextualizarlos científicamente.


En particular se analizan dos bloques de información: por un lado, se tiene la serie temporal de fulguraciones de GOES-18, la cual está bien estructurada, con variabilidad radiativa en escala de 1 minuto, y por otro se tiene los datos asociados a las CMEs, los cuales se relacionan con estructuras magnéticas de mayor complejidad y menos frecuencia de aparición. Esta distinción es indispensable para entender la estabilidad de las métricas logradas para ambos casos.

- Fulguraciones (GOES-18)

La muestra para la predicción de fulguraciones proviene del registro XRS del GOES 18 a resolución de 1 minuto, como se ha mencionado en el Capítulo 4. La variable de estudio para este caso la constituye la probabilidad de que ocurra una fulguración M/X en los próximos 45 minutos. La etiqueta que se ha definido marca como positivo cada minuto dentro de los 45 minutos previos al pico de una fulguración M/X. De esta manera se convierte en un problema coherente con la dinámica de crecimiento rápido del flujo XRS antes de las fulguraciones energéticas. El historial de entrada, es decir, el contexto que adquiere el modelo se ha fijado en 6 horas, en concreto, los modelos se alimentan con secuencias de 120 minutos desde las que se infiere si el sistema entrará en fase M/X en el siguiente tramo de 45 minutos.

La serie se segmenta por fechas, el conjunto de entrenamiento desde enero hasta agosto de 2025, el de validación septiembre y el de prueba octubre de 2025, para así garantizar una evaluación temporal honesta y manteniendo el desbalance real de la clase positiva, con una prevalencia de alrededor del 7% en el conjunto de prueba. Para resaltar los cambios del flujo XRS se calcularon promedios móviles (entre 5 y 15 minutos) para suavizar el ruido, así como relaciones entre promedios de distintas duraciones, los cuales pueden indicar una subida de la radiación. También se normalizó cada valor. Estos pasos se hacen con el objetivo de que el modelo sepa reconocer momentos de intensidad de flujo que aumenta, es decir, momentos previos a un evento.

*Figura 5: Flujo de rayos X obtenido por XRS con sus picos en el rango temporal a estudiar. (GOES-18)*



- Eyecciones de masa coronal (CMEs)

Para el caso de CMEs, como se ha mencionado en el Capítulo 4, se ha trabajado con el catálogo de CMEs de SOHO y con los parámetros magnéticos SHARP de SDO. Como objetivo se ha planteado en enfocarse en las CMEs más energéticas, y se ha definido la clase positiva cuando cumple una velocidad de propagación  $> 500\text{km/s}$  y una anchura  $> 70^\circ$ . Este criterio amplía la cobertura de umbrales más estrictos para abarcar un mayor número de positivos y poder aplicar los modelos predictivos.

La construcción para este caso se ha realizado con una resolución horaria. Para cada hora, se agregan las magnitudes SHARP que contienen más información sobre la complejidad del campo, tales como USFLUX, MEANGAM, TOTPOT, TOTUSJZ, R\_VALUE (su contenido se explica en el Capítulo 4). A continuación, se ha generado un historial de 24 horas, la cual sirve como ventana de contexto y describe su evolución reciente. Luego se ha etiquetado cada punto temporal como una variable binaria que dice si ocurrirá una CME energética en las siguientes 10 horas, que son las horas en las cuales se ha fijado el horizonte de predicción debido al escaso de eventos. Esto quiere decir básicamente que el modelo observa 24 horas de variación magnética a través de esos parámetros y responde si en las 10 horas posteriores a  $t$  se producirá una CME calificada como energética.

Para relacionar cronológicamente cada registro SHARP con un evento del catálogo SOHO, se ha utilizado un emparejamiento temporal con tolerancias amplias, tras las cuales se aplica el filtro de 10 horas y decide la etiqueta.


Hay varios puntos importantes que aclarar: en el caso de las eyecciones de masa coronal, la señal es mucho más compleja que para el caso de las fulguraciones. Aquí se observa una gran complejidad de parámetros magnéticos que pueden causar grandes dificultades para balancear los modelos predictivos.

## 5.2 Resultados obtenidos

### - Fulguraciones (GOES-18)

Los resultados obtenidos en la predicción de fulguraciones de tipo M/X muestran un desempeño muy consistente. La curva precisión-recall (Figura 6) muestra la capacidad del modelo para mantener una alta precisión incluso en valores elevados de recall, lo cual no es nada fácil debido al desbalanceo de clases.


*Figura 6: Curva precisión-recall para la predicción de fulguraciones del modelo CNN en el conjunto de prueba.*



El área bajo la curva ROC alcanzó un valor de 0.88 lo cual reafirma la capacidad del modelo para diferenciar los eventos altamente energéticos, en este caso fulguraciones de tipo M/X de las que no lo son.

Tras fijar el umbral de decisión en 0.262, se ha conseguido un equilibrio más que razonable para estos casos. La red logra una precisión de 0.55 con un recall de 0.89, valores muy satisfactorios teniendo en cuenta la poca frecuencia de estos sucesos y que, para este caso, se busca un recall alto más que una precisión elevada, ya que tiene más sentido las “falsas alarmas” que el hecho de no captar una fulguración energética. En la matriz de correlación se observa que el modelo identifica correctamente la mayoría de los eventos, con un número asumible de falsos positivos.

*Figura 7: Comparación entre fulguraciones reales y predichas con la red CNN, con los valores de verdaderos positivos, falsos positivos y falsos negativos.*



En la Figura 7 se ven como las predicciones, mayormente, se encuentran alrededor de los eventos reales, confirmando la capacidad del modelo de predicción.

La tabla de resultados de la Figura 8 muestra la coherencia de las métricas global obtenidas para ambas clases para el modelo CNN, alcanzando una precisión global del 94.3%, con una precisión de 0.55 y un recall de 0.889 para la clase positiva. También se observa un valor para F1-score razonable,


0.6769 para la clase positiva. Todo esto indica que el modelo acierta 9 de cada 10 eventos aproximadamente, con una precisión asumible.

*Figura 8: Métricas para la predicción de fulguraciones de tipo M/X con la red CNN unidimensional.*

| CNN: AP=0.860   umbral=0.262   P=0.550 R=0.889 |           |        |          |         |
|------------------------------------------------|-----------|--------|----------|---------|
|                                                | precision | recall | f1-score | support |
| 0                                              | 0.9916    | 0.9472 | 0.9689   | 14879   |
| 1                                              | 0.5501    | 0.8889 | 0.6796   | 1080    |
| accuracy                                       |           |        | 0.9433   | 15959   |
| macro avg                                      | 0.7709    | 0.9181 | 0.8243   | 15959   |
| weighted avg                                   | 0.9617    | 0.9433 | 0.9493   | 15959   |

En paralelo, la red LSTM muestra un rendimiento muy similar al de la red CNN, con una precisión de 0.55 y un recall de 0.878. Su desempeño, aunque bueno, tiende a ser ligeramente menos sensible ante picos algo más sensibles.

*Figura 9: Comparación entre fulguraciones reales y predichas con la red LSTM, con los valores de verdaderos positivos, falsos positivos y falsos negativos.*



En la Figura 9 se observa que ya no es tan claro que las predicciones estén alrededor de las fulguraciones reales. A pesar de esto, las métricas son más

que aceptables como se muestra en la Figura 10, con un alto recall y un F1-score casi idéntico al de la red CNN.

*Figura 10: Métricas para la predicción de fulguraciones de tipo M/X de la red LSTM.*

|                                                 |           |        |          |         |
|-------------------------------------------------|-----------|--------|----------|---------|
| LSTM: AP=0.785   umbral=0.359   P=0.550 R=0.879 |           |        |          |         |
|                                                 | precision | recall | f1-score | support |
| 0                                               | 0.9908    | 0.9478 | 0.9688   | 14879   |
| 1                                               | 0.5501    | 0.8787 | 0.6766   | 1080    |
| accuracy                                        |           |        | 0.9432   | 15959   |
| macro avg                                       | 0.7705    | 0.9133 | 0.8227   | 15959   |
| weighted avg                                    | 0.9610    | 0.9432 | 0.9491   | 15959   |

En conjunto, los modelos han presentado un rendimiento notable en general. En la métrica que más interesa para el contexto, la red CNN unidimensional ha alcanzado una sensibilidad o recall del 89% y la red LSTM del 88% con una precisión que se ha fijado en 0.55 para maximizar el recall. Esto ofrece un punto de partida muy sólido para un sistema de alerta temprana, y las evidencias observadas muestran que las fulguraciones presentan patrones radiativos claramente diferenciables en los minutos previos al estallido mediante redes neuronales.

- Eyecciones de masa coronal (CMEs)

Los resultados para la predicción de CMEs energéticas no han sido lo que se buscaba. En la fase de validación, con un umbral estándar de 0.5, el modelo alcanza una precisión de 0.245 y un recall de 0.204, con un área bajo la curva ROC de 0.555. El conjunto de prueba mantiene los valores en la misma línea, con una precisión de 0.187, un recall de 0.388 y un área bajo la curva ROC de 0.543. Esto indica que el modelo indica alguna CME verdadera, pero casi que podría ser por azar debido a su alta tasa de falsos negativos.

Figura 11: Resultados para la predicción de CMEs energéticas de la red CNN unidimensional.

```

=== VALID @ p>=0.5 ===
      precision    recall  f1-score   support

     0       0.792      0.828      0.810       2227
     1       0.245      0.204      0.223        607

   accuracy          0.694       2834
  macro avg          0.519      0.516       2834
 weighted avg          0.675      0.694      0.684       2834

Confusion matrix [tn fp; fn tp]:
[[1844  383]
 [ 483 124]]
Extra: Recall_1=0.204 | Recall_0=0.828 | Precision_1=0.245 | AUROC=0.555 | AUPRC=0.250

=== TEST @ p>=0.5 ===
      precision    recall  f1-score   support


     0       0.877      0.721      0.791       2433
     1       0.187      0.388      0.252        402

   accuracy          0.673       2835
  macro avg          0.532      0.554       2835
 weighted avg          0.779      0.673      0.715       2835

Confusion matrix [tn fp; fn tp]:
[[1753  680]
 [ 246 156]]
Extra: Recall_1=0.388 | Recall_0=0.721 | Precision_1=0.187 | AUROC=0.543 | AUPRC=0.229

```

Figura 12: Comparativa de CMEs reales y predicciones del modelo CNN.



En conjunto, la red CNN detecta algunos patrones, pero no puede lograr establecer una frontera clara entre las regiones que acaban generando una CME energética y aquellas estables. La complejidad magnética de los datos es una limitación clara para la detección de patrones.

Los resultados del modelo LSTM mejoran un poco en cuanto al recall para la clase 1 pero la clase 0 pierde mucha sensibilidad, obteniendo un área bajo la curva ROC muy bajo, 0.485.



Figura 13: Figura 11: Resultados para la predicción de CMEs energéticas de la red LSTM.

```
[VAL] thr*=0.235 | P=0.231 | R=0.451

=== TEST REPORT (umbral fijado por validación) ===
      precision    recall  f1-score   support

         0       0.860      0.443      0.585        2433
         1       0.143      0.562      0.228         402

   accuracy                        0.460        2835
  macro avg       0.501      0.503      0.406        2835
 weighted avg     0.758      0.460      0.534        2835

Confusion matrix [tn fp; fn tp]:
[[1078 1355]
 [ 176  226]]

Extra:
  Recall_1 (sensibilidad) = 0.562
  Recall_0 (especificidad) = 0.443
  Balanced Accuracy      = 0.503
  AUROC (scores) = 0.485
```

En definitiva, se ha confirmado la alta dificultad de detección de CMEs altamente energéticas. Pese a una proporción razonable, de entorno un 18%, las características magnéticas disponibles no bastan para una predicción robusta. El modelo LSTM tiene un recall aceptable de 0.56 pero a costa de una precisión mínima y a causa del bajo recall de la clase 0. A pesar de esto, el comportamiento observado puede sugerir que existe algún indicio de pre-erupción de CMEs energéticas en los datos SHARP, que combinándolos con observaciones cronográficas (imágenes de la corona solar) se podría mejorar la capacidad discriminativa y el poder predictivo de este.

### 5.3 Discusión y análisis de los resultados

Los resultados obtenidos reflejan claramente la diferencia que existe en la predictibilidad entre las fulguraciones solares y las eyecciones de masa coronal. En el primer caso, la predicción de fulguraciones de tipo M/X, el comportamiento del modelo confirma la fiabilidad y los patrones bien definidos que contiene la señal radiativa de XRS del satélite GOES. Las redes neuronales son capaces de reconocer los incrementos del flujo de rayos X y

traducirlos a una probabilidad de ocurrencia de las fulguraciones. El valor tan elevado del área bajo la curva ROC confirma la capacidad de discriminación del modelo, y el balance entre precisión y recall alto demuestra que el modelo es capaz de captar esa fase de crecimiento de la emisión y traducirlo a una probabilidad. Desde el punto de vista de la física, esto sugiere que el flujo de rayos X de XRS es un indicador directo y rápido de la actividad energética inminente, lo que podría sugerir que estas herramientas podrían ser útiles para sistemas de alerta temprana.

En el segundo caso se observa que el comportamiento de las eyecciones de masa coronal (CMEs) parece que es mucho más complejo y pone en evidencia las limitaciones de su predicción que se basan únicamente en parámetros magnéticos. A pesar de los umbrales propuestos, el modelo no logra superar de forma consistente el umbral de discriminación aleatoria con un área bajo la curva ROC de alrededor de 0.5. Esto indica que las variables SHARP, aunque son útiles para entender la complejidad magnética, no contienen información suficiente para predecir de forma fiable la liberación de masa coronal. Físicamente, esto se puede explicar ya que la mayoría de CMEs ocurren en las capas más altas de la atmósfera solar y dependen de configuraciones tridimensionales del campo que no quedan reflejados en los parámetros magnéticos de SHARP en su totalidad.

Desde un punto de vista metodológico, basándose en la literatura, los resultados son coherentes: los modelos basados en SHARP únicamente o medidas de parámetros magnéticos no superan un área bajo la curva ROC de 0.6, ligeramente superior al conseguido, lo que confirma la dificultad del problema. A pesar de eso, algunos factores como una subida en el recall pueden insinuar que, con más información de imágenes de la corona solar, donde la expansión de bucles coronales, por ejemplo, pueden aportar la información necesaria para un modelo más robusto y utilizable.

El trabajo es replicable y permite evaluar distintos rangos temporales y arquitecturas con datos solares, por lo que se considera que aunque los resultados son muy diferentes para los dos casos de estudio, principalmente

por limitaciones en los parámetros físicos, el estudio demuestra que la inteligencia artificial es capaz de extraer patrones significativos de la actividad solar extrema y puede ser útil para sentar una base para desarrollar modelos predictivos cada vez más fiables y completos.

## Capítulo 6: Conclusiones

El desarrollo del trabajo ha permitido cumplir con los objetivos planteados al inicio, tanto el objetivo general como los específicos. Se detalla a continuación la relación de cada uno de ellos con los resultados y su justificación:

- Objetivos específicos

1. Revisar la literatura científica y los fundamentos físicos de las fulguraciones y CMEs.

Este objetivo se ha alcanzado al completo. En el marco teórico se ha realizado un estudio detallado de los procesos físicos que ocurren implicados para ambos fenómenos, como la reconexión magnética o la dinámica del plasma, así como los principales enfoques que se han utilizado para la predicción de estos. Se han analizado también trabajos previos publicados basados en modelos de machine learning y deep learning, lo que ha permitido contextualizar el proyecto y justificar el uso de las arquitecturas utilizadas para la predicción.

2. Limpiar, preprocesar y analizar los datos procedentes de SDO, GOES y SOHO.

El segundo objetivo específico también se ha cumplido de manera satisfactoria. Se ha diseñado un proceso de tratamiento de datos desde la

descarga de estos, hasta la obtención de datos fiables y representativos gracias a la sincronización temporal, normalización, construcción de ventanas de observación deslizantes y horizontes de predicción coherentes para cada fenómeno. El hecho de tener unos datos limpios y fiables es un requisito indispensable para el entrenamiento de modelos robustos de predicción.

### 3. Diseñar e implementar distintos modelos predictivos (CNN y LSTM).

Otro objetivo que se ha cumplido totalmente. Tras el análisis de datos, se han desarrollado desde cero dos modelos de aprendizaje profundo, cada una ajustada a las características propias. En el caso de las fulguraciones, las redes han sido entrenadas sobre la señal radiativa XRS con ventanas de observación de 45 minutos y horizontes de predicción equivalentes, mientras que para las CMEs se han utilizado secuencias de 24 horas y parámetros magnéticos de SHARP para anticipar hasta 10 horas de antelación. Ambos enfoques han sido implementados desde cero con un control en las fases de entrenamiento, validación y test.

### 4. Comparar el rendimiento de los modelos mediante métricas de evaluación estándar.

Aunque la comparación no ha sido la principal fuente de análisis, el objetivo se ha cumplido. Se han calculado métricas ampliamente conocidas y aceptadas en el ámbito de meteorología espacial tales como la precisión, el recall, F1 score y AUROC. En el caso de las fulguraciones la CNN ha alcanzado valores para el recall de 0.89 y 0.55 para la precisión. Por el contrario, la LSTM ha alcanzado valores similares, un recall de 0.88 y una precisión fijada en 0.55. Ambos modelos satisfactorios, siendo el CNN el mejor por poco. Para el caso de las CMEs tampoco ha habido mucha diferencia, en este caso en el mal sentido. Ninguno de los modelos obtuvo unos valores mucho mas significativos que tirar una moneda al aire ( $AUC=0.55$  y  $precisión=0.2$ ), pero el análisis ha permitido extraer conclusiones significativas sobre las limitaciones del tipo de datos utilizado.

## 5. Aplicar los modelos a casos concretos del Ciclo Solar 25

Este objetivo se ha cumplido por el hecho de que los modelos se han entrenado, validado y probado con datos de observaciones recientes del Ciclo Solar 25, abarcando este periodo. Esto ha permitido verificar el rendimiento de los modelos en un entorno real y comprobar su capacidad para detectar patrones consistentes durante la primera fase del ciclo.

## 6. Extraer conclusiones y proponer líneas futuras de estudio

Este objetivo se cumple en el presente apartado. Las conclusiones son clave para entender las fortalezas y debilidades del trabajo y de los enfoques utilizados. Mediante estas, se proponen líneas futuras de estudio y las direcciones más prometedoras.

- Objetivo general

Desarrollar un modelo de predicción de actividad solar extrema mediante observaciones satelitales y aprendizaje profundo.

Este objetivo se ha cumplido al 100%. Se ha demostrado que el uso de técnicas de deep learning y mediante datos satelitales se pueden anticipar fenómenos solares con diferentes niveles de éxito según la naturaleza del evento y de los datos utilizados. El sistema que se ha creado puede reproducirse con facilidad insertando otro conjunto de datos y adaptarse a otros tipos de observaciones solares. Esto presenta una aportación práctica y real al uso de la inteligencia artificial en la predicción de actividad solar.

## 6.1 Limitaciones

Durante todo el proyecto se han identificado varias limitaciones que contextualizan la calidad de los resultados obtenidos y los motivos por los cuales no se ha podido alcanzar un rendimiento más elevado en todos estos ámbitos.

El desequilibrio de clases ha sido la primera limitación afrontada. Los conjuntos están claramente desbalanceados, aunque finalmente ajustando los parámetros se ha conseguido una proporción de positivos de 7% para las fulguraciones y de 18% para las CMEs. Aun así, esta desproporción hace a que los modelos tiendan a priorizar la clase negativa, perdiendo estabilidad. Además de esto, la naturaleza y la calidad de los datos utilizados también han resultado ser limitaciones. En el caso de las CMEs, se han utilizado parámetros SHARP, buenos descriptores del campo magnético de la fotosfera del sol. El problema es que las CMEs se forman en la corona solar, una región que tiene un comportamiento distinto físicamente y alejada de la superficie. Esto implica un desfase conceptual entre la fuente y el fenómeno a predecir y como se ha visto, los parámetros fotosféricos no recogen de manera directa los procesos de reconexión que desencadenan una CME. Esta discrepancia constituye la causa principal del bajo rendimiento de los modelos para predecir CMEs.

También hay que destacar la escasez de eventos extremos. El periodo de análisis abarca una parte del Ciclo Solar 25, en fase ascendente, por lo que el número de fulguraciones X y de CMEs muy rápidas es muy reducido, por eso los umbrales que se han propuesto para una mayor muestra son más amplios y el hecho de no tener eventos muy energéticos puede hacer que no se detecte un patrón claro y que los modelos no generalicen bien.

Las arquitecturas utilizadas, aunque aceptadas, pueden constatar otra limitación del proyecto. Aunque ofrecen un desempeño notable en detección de patrones temporales, arquitecturas híbridas o otros modelos podrían

mejorar la sensibilidad sin incrementar los falsos positivos. Además de esto, la limitación computacional es otro punto clave. Durante el entrenamiento se ha reducido la profundidad de las redes y simplificado alguna fase del preprocesamiento. Esto podría influir en los resultados, un entorno más potente a nivel computacional podría aumentar el tamaño de las ventanas temporales, aumentar la cantidad de datos...

A pesar de todo, el conjunto de todas estas limitaciones no invalida los resultados obtenidos, los contextualizan, explicando porqué algunos resultados son sustancialmente mejores que otros. A su vez, señalan claramente el camino que se considera que se debería de tomar hacia futuras mejoras en la predicción de estos fenómenos, especialmente la necesidad de datos coronales que representen mejor los procesos implicados en las CMEs.

## 6.2 Prospectiva

Este trabajo abre múltiples líneas de continuidad futuras que pueden permitir ampliar el alcance y consolidar los resultados obtenidos.

La primera línea y más obvia es la integración de nuevas fuentes de datos procedentes de la corona solar y no de la fotosfera. Imágenes coronográficas del satélite SOHO o observaciones en ultravioleta extremo (EUV) del SDO pueden ser fuentes interesantes para empezar. Estos conjuntos permitirían una visión más completa de los parámetros que causan las CMEs ofreciendo información directa sobre los procesos previos a la eyección.

Desde un punto de vista más técnico y con visión hacia la inteligencia artificial, se podría desarrollar modelos multimodales, capaces de combinar datos de distinta naturaleza, tanto radiativos como magnéticos o visuales. Esta arquitectura híbrida podría ser la clave para mejorar de forma significativa la sensibilidad y capacidad de predicción de los modelos. Ejemplos de estos modelos multimodales pueden ser arquitecturas CNN-LSTM híbridas, donde la red CNN procesa imágenes y una LSTM analiza la

evolución temporal de los parámetros numéricos, pudiendo combinar la estructura espacial y la dinámica temporal. Otro ejemplo podrían ser los Transformers multimodales, que permiten integrar información de imágenes y series numéricas en un espacio de atención, pudiendo analizar simultáneamente magnetogramas, flujos radiativos y variables coronales.

También se podrían incorporar mecanismos de interpretación del modelo (Explainable AI) que permita identificar qué variables o momentos influyen más en la predicción. Si se combinase esta área con el conocimiento que se tiene de los eventos a nivel físico se podría optimizar mucho el trabajo y lograr mejores resultados

Finalmente, una proyección natural de este trabajo sería su transferencia hacia sistemas operativos de metodología espacial. Tras depurar el preprocesamiento y los modelos, integrarse en un entorno de monitorización en tiempo real conectado a flujos de datos actualizados de GOES, SOHO y SDO sería lo ideal. Con ello, se pretende avanzar hacia un sistema automatizado de alerta temprana de fenómenos solares, desde un punto de vista de la protección de infraestructuras espaciales y sistemas de comunicación.

### 6.3 Consideraciones finales

La elaboración del trabajo ha supuesto una experiencia muy enriquecedora tanto a nivel académico como a nivel personal. De hecho, a causa de este trabajo he encontrado la rama de la física a la que me quiero dedicar en mi futuro profesional. Los resultados obtenidos reflejan un esfuerzo por integrar conocimientos de física, análisis de datos y técnicas de inteligencia artificial en un proyecto coherente y con una aplicación real a nivel científico.

Desde un punto de vista técnico, en el proyecto se ha demostrado que la inteligencia artificial es una buena herramienta para detectar patrones reales de la actividad solar y contribuir en la predicción de fenómenos tales como las



fulguraciones o CMEs. Las fulguraciones se han mostrado altamente predecibles, probablemente por la claridad de su señal radiativa. Las CMEs, por el contrario, han mostrado la complejidad que tienen y la necesidad de incluir información de la corona solar para su predicción. Gracias a estas dos caras, se ha mostrado que una aplicación adecuada de la inteligencia artificial tiene que ir de la mano de conocimiento científico y calidad de los datos.

Gracias a este trabajo, he consolidado habilidades en el manejo de grandes volúmenes de datos satelitales, programación de Python, diseño de modelos predictivos y evaluación estadística de estos. Además, he fortalecido la capacidad de análisis crítico y he aprendido a trasladar conceptos físicos teóricos a un entorno aplicable mediante IA.

Desde un punto de vista más personal, además de aclararme las ideas de mi futuro, el trabajo ha representado un aprendizaje total, desde trabajar con datos reales de satélites que están ahora mismo obteniendo datos hasta utilizar herramientas de inteligencia artificial, probablemente el futuro del análisis de datos y observaciones astronómicas. Ha potenciado la autonomía investigadora, la capacidad de resolver problemas durante el proceso y la adaptabilidad en estos campos, me he dado cuenta de que la mayoría de las veces la idea que se tiene al principio sobre un proyecto o trabajo cambia durante el proceso por razones como la obtención y calidad de datos, rendimiento de modelos o razones físicas en este caso.

En cuanto a la autoevaluación, considero que el proyecto ha alcanzado sus objetivos plenamente, tanto en términos técnicos como en formativos. El enfoque ha sido el correcto, aunque hay varios puntos de mejora en la visualización de resultados o en la integración de nuevas fuentes de datos. De cara al futuro, como se ha comentado, habría que abordar este problema con diseños multimodales y con una interpretación física de las variables utilizadas.

Finalmente, quiero expresar mi agradecimiento a Juan Agustín Fraile Nieto por su orientación durante el trabajo, a mi familia y a mi novia por el apoyo constante y a los equipos científicos de la NASA y la NOAA por la accesibilidad de sus bases de datos de las observaciones satelitales.

No puedo concluir este trabajo sin expresar mi deseo de que los avances de la inteligencia artificial contribuyan al ámbito científico y al conocimiento para ampliar el conocimiento sobre distintos eventos naturales y estar más cerca de predecirlos y evitar futuras catástrofes. Espero que esta modesta contribución a la ciencia sirva como punto de partida hacia futuras investigaciones para integrar conocimientos de física con la inteligencia artificial en beneficio del progreso científico.

## Bibliografía

- Bobra, M. G., Sun, X., Hoeksema, J. T., Turmon, M., Liu, Y., Hayashi, K., Barnes, G., & Leka, K. D. (2014). The Helioseismic and Magnetic Imager (HMI) Active Region Patches (SHARPs): Space-Weather Targets for the HMI. *Solar Physics*, 289(9), 3549–3578. <https://doi.org/10.1007/s11207-014-0529-3>
- Boteler, D. H. (2019). A 21st century view of the March 1989 magnetic storm. *Space Weather*, 17(10), 1427–1441. <https://doi.org/10.1029/2019SW002278>
- Chen, P. F. (2011). Coronal mass ejections: Models and their observational basis. *Living Reviews in Solar Physics*, 8(1), 1. <https://doi.org/10.12942/lrsp-2011-1>
- Deng, Z., Wang, F., Deng, H., Tan, L., Deng, L., & Feng, S. (2021). *Fine-grained Solar Flare Forecasting Based on the Hybrid Convolutional Neural Networks*. [Preprint] arXiv:2109.13428. <https://arxiv.org/abs/2109.13428>
- Green, L. and Baker, D. (2015), Coronal mass ejections: a driver of severe space weather. *Weather*, 70: 31-35. <https://doi.org/10.1002/wea.2437>
- Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Howard, R. A., Vourlidas, A., & Stenborg, G. (2023). The evolution of our understanding of coronal mass ejections. *Frontiers in Astronomy and Space Sciences*, 10. <https://doi.org/10.3389/fspas.2023.1264226>

- LeCun, Y., Bengio, Y., & Hinton, G. (2015). *Deep learning*. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Liu, Y., Zhang, X., & Zhao, J. (2024). Prediction of Geoeffective CMEs Using SOHO Images and Deep Learning (GeoCME). *Solar Physics*, 299(4), 52. <https://doi.org/10.1007/s11207-024-02385-w>
- NASA. (2024). *Artificial Intelligence Model “Surya” Improves Solar Flare Forecasting*. NASA Science News. <https://science.nasa.gov/science-research/artificial-intelligence-model-heliophysics/>
- NASA. (2024). *Solar cycle 25 is Exceeding Predictions and Showing Why We Need the GDC Mission*. NASA Goddard Space Flight Center. [Solar Cycle 25 is Exceeding Predictions and Showing Why We Need the GDC Mission - NASA Science](https://science.nasa.gov/solar-cycle/solar-cycle-25-is-exceeding-predictions-and-showing-why-we-need-the-gdc-mission)
- Priest, E. R., & Forbes, T. G. (2002). *The magnetic nature of solar flares*. *The Astronomy and Astrophysics Review*, 10(4), 313–377. <https://doi.org/10.1007/s001590100013>
- Santos, M., Guastavino, F., & Rigo, F. (2025). *Explainable AI in Deep Learning-Based Prediction of Solar Storms*. <https://arxiv.org/abs/2508.16543>.
- Shibata, K., & Magara, T. (2011). Solar flares: Magnetohydrodynamic processes. *Living Reviews in Solar Physics*, 8(1), 6. <https://doi.org/10.12942/lrsp-2011-6>
- Wang, H., Liu, C., & Deng, N. (2024). *Advancing Solar Flare Prediction Using Deep Learning with Active Region Patches*. <https://arxiv.org/abs/2406.11054>.



# Anexos

Código en colab, links:

<https://colab.research.google.com/drive/1b8V8QOZtoqrNZyfNTHO6lNUP7muvXEpP?usp=sharing>

<https://colab.research.google.com/drive/19C5ZVmAYNP5BsOKqjmDnQjYpNgsUOq9?usp=sharing>